让 Agent 的输出由目的驱动，而不是由 token 驱动

第四组·架构化状态机 v1–v5 的五轮测量

2026-10-24

目录

摘要 **3**

1 引言 **4**
1.1 问题 4
1.2 为什么这不容易 4
1.3 我们的做法 4
1.4 贡献 5

2 相关工作 **5**
2.1 生成机制一侧：NTP 与"先想再写" 5
2.2 测量一侧：创造性写作的交互式基准 5
2.3 驱动「」一侧：状态、立场与角色 5

3 问题设定 **6**
3.1 主张的边界（先说不能主张什么） 6
3.2 两条通路 6
3.3 研究问题 6

4 方法 **6**
4.1 架构化状态机（v1 → v3） 6
4.1b ★ v4 / v5：把状态放进选择层（架构） 7
4.2 臂 7
4.3 探针 8
4.4 ★ 不循环读数（本文的核心方法论贡献） 8
4.5 判官读数 8
4.5.1 绝对打分：天花板效应与判官自检 8
4.5.2 两两比较：位置去偏是硬闸 8
4.6 预注册与纪律 9

5 实验设置 **9**
5.1 题 9
5.2 模型与批 9
5.3 判官自检（先证明检查器能抓到东西） 9
5.3b ★ v4 / v5 的实验设置 9
5.4 规模与成本 10

6 结果 **10**
6.1 反馈通路：成立且强分离（v1 批次） 10
6.2 驱动力通路：在几何读数上归零（v3 批次，NL 通道） 11

6.3 ★ 换用判官读数：方向相反 11
6.3.1 同源判官 MiniMax-M3 ·三题（G01 / T07 / T10） 11
6.4 ★ 双判官交叉验证：方向不是某个判官家族的偏好 12
6.5 零判官几何读数（多题） 13
6.6 失败与闸门（显式列出，不静默剔除） 13
6.7 ★ v4：把状态放进选择层（而不是提示层） 14
6.8 ★ v5：编号化取舍声明 + 结构化绑定，以及一个统一的失败诊断 15

7 讨论 **16**
7.1 两条读数轴：可核验性 × 分辨力 16
7.2 判官读数的三个失效模式（可复用的流程建议） 16
7.3 失败的结构性根因：取舍对象取自初稿已有内容 17
7.4 对相邻结论的独立验证与指引 17
7.5 局限与威胁有效性 17
7.5b ★ v4 / v5 新增的局限与威胁有效性 18
7.6 同源判官：能用，但只能当交叉验证的一端 18
7.7 ★ v4 的结构性两难：状态化选择要么无效、要么恒真 19
7.8 ★ 把"驱动力"从内容改写为结构：情感与观点的统一 19
7.9 ★ v3 的失败为什么仍未解释（本文留下的一个诚实缺口） 20

8 结论 **20**

参考文献 **21**

附录 A ·复现清单 **23**
A.1 代码 23
A.2 数据 23
A.3 关键命令 24
A.4 复现注意事项（踩过的坑） 24

附录 B ·判官失效模式速查 **25**

副标题：把"驱动力"从一种内容改写为一个结构 —— 状态 → 改变了哪一个可核验的选择 → 代价是什么

摘要

主流大语言模型按下一个词的概率续写，产出因此倾向于"流畅但无主"。要让 Agent 的写作像人一样**由情感或观点推动**，自然的做法是给它一个持久状态：先形成立场，再由状态组织每一步的取舍。但**如何测量"改变"是由目的（思想/情感）驱动的，而不是被 prompt 措辞或采样噪声带出来的，一直缺少一个干净的实验协议**——而且这个测量本身极容易出错。

本文把"驱动"拆成三**条通路**（反馈 / 驱动力 / 选择层），给出各自的读数与地板，并报告五个方法学发现与一个跨代际的失败收敛。

① **反馈通路**（观测 → 状态 → 产出）成立且强分离：效应量是纯重跑方差的 **9.13**×。

② **判据的循环性**。当状态经由**代码强制**（必含/禁含实体）生效时，「状态变了 ⇒ 产出变了」是**恒真命题**，不能充当驱动力证据。我们给出唯一不循环的读数设计（决策只以自然语言进入生成流程，此时产出的变化才是模型的选择），并把它写成一条可迁移的检查题：「**这个读数能不能是恒真的?**」

③ ★ **我们的负结果是读数错配的产物**。在几何读数（实词 2/3-gram Jaccard）上，G01 单题的 15 个臂对全部落在 0.053–0.077 的窄带内，而纯重跑地板是 0.0720 ⇒ 地板高于信号，状态机"无增量"；换用**对着目标直接问的判官两两比较**后，同一批产出给出**方向相反**的分离：在通过位置一致率硬闸的对比中，状态机在 3 题 × 3 维度上**一致优于直答臂**（D1 汇总 3 胜 15 负、D3 汇总 1 胜 17 负，位置一致率均 0.889），并在 G01 上优于等预算自我说明与提示词状态机（L0）。⇒ 我们据此主张：在创作任务上，**"状态是否驱动了产出"不能用产出之间的相似度来回答**——相似度测的是"内容在哪里"，而驱动是关于"内容里有什么"。⚠ 我们同时报告**反向证据**：T10 上 D1 的 A vs WF-a3 是 3 胜 3 负（唯一例外），且多题判官因额度限制只能由**同源**判官承担 ⇒ 实质结论仍需跨厂商判官与人类盲评。

④ ★ **双判官交叉验证**。同源判官与被测共享偏好，因此我们把同源判官与两个跨厂商判官（grok）在 G01 上对照：三**个判官在核心对比上给出完全相同的数字（0 胜 6 负，位置一致率 1.00）**，方向在六个对比中全部一致 ⇒ **该方向不是某个判官家族的偏好**。> ⚠ ⚠ **【限定，2026-10-24 补】位置一致率 ≠ 重复判定的可复现性**。本文的「位置一致率」测的是**同一对文本、交换 A/B 位置各判一次** ⇒ 它排除的是**位置偏差**；它**没有**测「同一顺序重复判定」的波动（三组报告：同判官重复判定波动 0–1，而带 thinking 的模型可达 3）⇒ ⇒ **"三个判官给出完全相同数字"只能说明「这一次读数恰好落在同一侧」，不能直接读成"方向稳健"** ⇒ ⇒ 我们把判官读数的可复现性列为**未闭合的威胁**，并因此把第四组后续全部主读数改为**零判官**（§6.7–§6.8）。

我们同时量化了判官读数的三**种失效模式**（天花板效应、位置偏差、严格度差异），并把**位置去偏 + 一致率硬闸**作为 LLM-as-judge 成对比较的标准前置条件：实测中多对对比的胜负为"3 胜 3 负"（看似无差异），而其**位置一致率为 0.00**——真相是判官在随机作答。

⑤ ★ **把"驱动力"从一种内容改写为一个结构：情感与观点的统一**。我们主张 **驱动力 = 状态 → 改变了哪一个可核验的选择 → 代价是什么**。在 agent 架构里，情感与观点是同一类对象（都是约束下一步动作的持久状态），因而可用**同一套取舍层读数**测量；这把"文中有无感情词 / 有无观点句"这类**素材层**判据排除在外，并给出一个可证伪的**类型不变性**主张。⚠ 本文 v1–v5 测的全部是**观点型**状态，情感型状态一次都没进过实验 ⇒ 我们的结论不可外推到情感。

⑥ ★★ **一个跨代际的失败收敛：问题不在选择器，在状态本身**。我们把状态改放进**选择层**（v4：状态 → K 个完整候选 → 打分 → 选 1，取舍代价的对手方是被放弃的候选），并进一步用**编号化取舍声明 + 结构化绑定**（v5：候选自己声明「写透哪几个、放弃哪几个」，打分 = 声明的编号集 vs 状态决策的编号集，**离散、零措辞依赖**）以绕开"候选照做就能命中 ⇒ 打分恒真"的两难。判决是：在**候选拿不到状态内容**的干净条件下，状态化打分与通用打分**没有可测差距**（v4 判决臂 9/9 完全打平；v5 方向 3 胜 0 负 15 平、gap +0.088，未达预注册阈值）。⇒ 但 v5 同时量化了两个更有价值的量：候选声明"我要写透 X"时**只有 52.8% 真的写到**，声明"放弃 Y"时**仍有 33.3% 写了 Y** ⇒ **"说**

了取舍"不等于"做了取舍"；以及一个统一诊断——**54 个决策里只有 3 个（6%）是"放弃"** ⇒ 我们的状态构建**几乎不产生取舍代价**，而第四组的靶子恰恰是「有立场的 Agent 必须放弃一个更优候选」⇒ ⇒ **v4/v5 的弱结果可能共享同一根因：状态里没有代价，也就无所谓驱动力**。> ⚠ ⚠ **【限定，2026-10-24 补】这一根因不能回溯到 v3**。事后重算 v3 的决策分布：**"放弃"占 15%（4/26 个决策）、4/9 = 44% 的样本含"放弃"**——而 **v3 依然失败** ⇒ ⇒ **"有代价"本身不充分** ⇒ ⇒ 代价必须**进入选择器的排序**才可能起作用（这正是下一步 2×2 设计的直接来源）。⇒ 下一步因此从"改进选择器"改写为"**让取舍代价真实存在**"（把"放弃"变成状态构建的结构性配额）并把判据从**声明**移到**行为**。

最后，我们定位了一个结构性根因并据此指出方向：取舍的对象若取自初稿已有的内容，取舍便退化为"保留还是删掉"，被模型的改写惯性淹没。这与近期从训练侧得到的结论一致（要让模型"先想再写"，必须改训练目标并把随机性从输出端挪到输入端）⇒ **单靠推理时架构不足以制造驱动力**，本文的贡献是给出定位与一套可廉价复用的检验工具。

关键词：LLM 代理·状态驱动生成·创造力测量·判据效度·位置偏差·预注册

---

1 引言

1.1 问题

大语言模型的生成机制决定了它倾向"检索并续写"：给定上文，最大化下一词的概率。文学理论早已指出，不确定性是创造表达的**必要条件**；而对齐策略恰恰把模型推离不确定输出。近期的多方证据都指向同一处：

- NTP 架构倾向**表面连贯**，而非自发性、原创性与即兴风险；把创造力重新定义为**互动过程**而非预测输出，被明确提出为方向 [Olatunji & Sheppard 2025]。
- NTP **学不到**「先形成一个抽象想法（leap），再围绕它生成内容」的模式；在置换不变的任务上没有任何 token 重排能救 NTP ⇒ 解法必须换**训练目标**（teacherless / diffusion）并把随机性从输出端挪到输入端（seed-conditioning）[ICML 2025 杰出论文]。
- 人类写作的"无不确定性"**显著高于**模型输出（中位 NLL 比率 2.03–3.9），且指令微调与推理模型**加剧**这一差距 [Sui et al. 2025]。

我们关心的正是这条线上的工程问题：**在一个不能改训练目标的既有模型上，能否靠推理时的架构，让输出由观点驱动?**

1.2 为什么这不容易

一个自然方案是给 Agent 一个**持久状态**（立场、取舍、约束），让每一步生成都由状态组织。但这个方案有一个被反复忽略的陷阱：

> 在无状态自回归 LLM 上，「自己承担的」与"外部指令的"**机制上没有区别**，只有 token 来源不同。

也就是说，「把状态写进 prompt」与「写一条精心设计的提示词」在机制上同构。若不做设计，实验测到的任何差异都可能只是**提示词效应**，而非**驱动力**。这正是"状态机"这类工作最常见的失败模式：做得更复杂，而证据并未更强。

1.3 我们的做法

我们不追求"证明状态机有用"，而是把问题变成**可证伪的测量问题**：

1. **把"驱动"拆成两条通路**，分别给读数（§3）。
2. **为每条读数配三个地板**：纯重跑地板（D0）、无关刺激/盲从地板（D3）、以及**不循环读数**（§4.4）——这一条是本文最重要的方法论贡献。
3. **三轮迭代**（v1 干净但无力 → v2 更干净但更无力 → v3 引入不循环读数）⇒ 负结果是设计出来的，不是碰巧撞上的。
4. 全部实验**预注册先于结果**；失败与解析失败**显式标记**，不静默剔除。

1.4 贡献

- **C1 ｜通路的分离与可复用的实验协议**。反馈通路（观测 → 状态 → 产出）、驱动力通路（取舍内容 → 产出）与**选择层通路**（状态 → 候选集合 → 选择）此前被混用；我们给出各自的零判官读数、探针与地板设计（§3–§4）。
- **C2 ｜判据的循环性：一个可迁移的审查问题**。当状态经代码强制生效时，「状态变了 ⇒ 产出变了」是恒真命题。本文给出唯一的非循环读数设计，并把它写成一条通用检查：「**这个读数能不能是恒真的?**」（§4.4）
- **★C2′ ｜把"驱动力"从内容改写为结构：情感与观点的统一判据**。我们主张 **驱动力 = 状态 → 改变了哪一个可核验的选择 → 代价是什么**；情感与观点是同一类对象（都是约束下一步动作的持久状态），因而可用**同一套取舍层读数**测量。这把"文中有无感情词 / 有无观点句"这类素材层判据排除在外，并给出一个可证伪的**类型不变性**主张（§7.8）。
- **C3 ｜两个负结果，以及它们的机制解释**。在唯一不循环的读数上，驱动力通路**归零**（v3）；把状态改放进**选择层**后仍**归零**（v4，判决臂 9/9 完全打平）。两次失败合起来定位出**结构性两难**：「状态化选择」要么无效、要么恒真（§6.7、§7.7）。⇒ 失败不在"状态进不了产出"（状态塑造候选有效，9 倍），而在"**选择器读不出状态**"。
- **C4 ｜对相邻结论的独立验证与指引**。我们的结果从**推理时架构**一侧独立复现了"单靠 prompt 侧组织不足"的结论，并把下一步明确指向**训练目标与采样端**（§7）。

---

2 相关工作

2.1 生成机制一侧：NTP 与"先想再写"

- **[Olatunji & Sheppard 2025, arXiv:2505.19277]** 论证 token 预测与真正创造力在根本上不一致，架构倾向表面连贯而非自发性与即兴风险；以 battle rap 为案例显示预测系统无法真正参与对抗性或情感共鸣的交流；主张把创造力重新定义为**互动过程**。⇒ 与本文的关系：它给出**问题侧的正面表述**；本文给出**推理时架构侧的第一次严格测量**。
- **[ICML 2025 杰出论文, "Roll the Dice & Look Before You Leap"]** 指出 NTP 学不到「先想一个抽象点子再围绕它生成」的模式（作者称之为 leap of thought）；在置换不变任务上无 token 重排可救；解法是换训练目标（teacherless / diffusion）并做 **seed-conditioning**（把随机性从输出端挪到输入端，一次决定走哪条 plan，采样本身完全确定）。⇒ 与本文的关系：**最关键的对照坐标**。它说明"把 leap 写进 prompt"很可能不够，必须改训练/采样 ⇒ 与本文 §7 的指引一致。

2.2 测量一侧：创造性写作的交互式基准

- **WritingBench**：每个 prompt 动态生成 5 条**题定制评分准则**，专用 critic 模型（Qwen-2.5-7B，50K 标注）与人评 pairwise 一致率 83%。
- **LoTbench**：把创造任务化为掩码语言建模，引入 **DAESO（Different Approach, Equally Satisfactory Outcome）**与**因果评估器**（对创作链上的符号节点做干预）。
- **LLM Review**：盲审多代理协议，用代理间互评替代单一评审。⇒ 与本文的关系：本文**不做**质量基准式评分，而是研究**状态是否驱动了产出**；但采纳其"**盲化 + 题定制准则 + 因果干预**"三项方法学。

2.3 驱动「」一侧：状态、立场与角色

已有工作证明**外部指令**能改变内容层：PNAS Nexus 的 1,912 人预注册实验、persona prompting 的溢出效应等。**没有任何文献证明"模型自担的内在状态"能改变内容层**——而这正是本文要检验的（也正是本组必须先把主张从"模型内部"降级为"agent 进程内持久状态"的原因，见 §3.1）。

---

3 问题设定

3.1 主张的边界（先说不能主张什么）

本文**不**主张、也**不**试图证明"模型有内在状态"或"内容有思想质量"。原因是机制性的：

> 在无状态自回归 LLM 上，「自己承担的」与"外部指令的"在机制上无区别。

因此本文的靶子被明确限定为：**agent 进程内的持久状态，能否组织生成，使产出结构被改变，且该改变可归因**。机制证据**只能来自取舍层**（选了什么 / 没选什么 / 放弃了什么）；所有风格层位移只作诊断，不作机制证据。

★ v4/v5 之后，本文把"驱动力"进一步改写为一个结构（详见 §7.8）：

> **驱动力 = 状态 → 改变了哪一个可核验的选择 → 代价是什么**。

这样做的直接后果是：**情感与观点落在同一套读数之下**——它们都是进程内的持久状态，都只约束「下一步动作往哪边去」；而判据一律落在**取舍层**（选了什么 / 放弃了什么 / 声明与行为是否兑现），不落在"文本里有没有感情词 / 有没有观点句"这类**素材层**。

3.2 两条通路

通路	定义	读数	地板
反馈通路	观测 → 状态 → 产出	换观测后产出是否改变，且改变锚定在状态而非历史	D0 纯重跑
驱动力通路	取舍内容 → 产出	换取舍后产出是否改变	D0 纯重跑 + D3 无关刺激
★ 选择层通路（v4/v5 新增）	状态 → **候选集合** → 选择	状态化打分选出的候选，其「声明与状态决策的一致度」是否高于通用打分选出的候选	`*-blind` 臂（盲选地板）

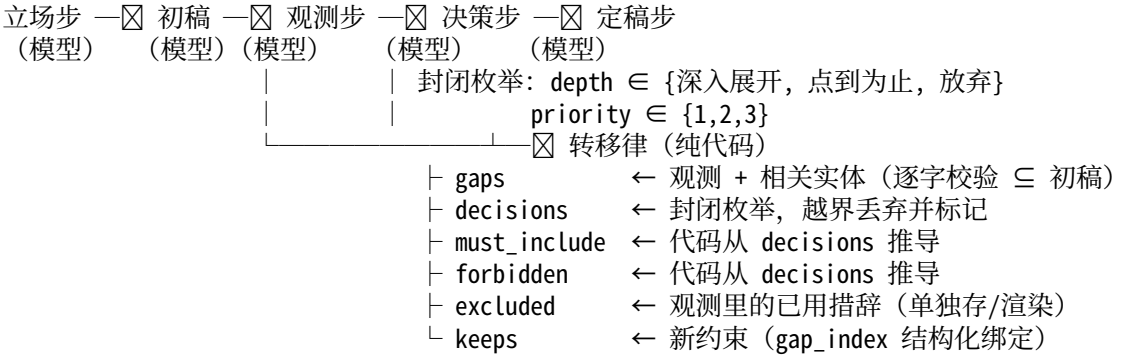
3.3 研究问题

- **RQ1**：反馈通路是否存在且可归因?
- **RQ2**：在**不循环**的读数上，驱动力通路是否存在?
- **RQ3**：架构化状态机相对**等预算的自我说明**（同调用数、含取舍意识、但无状态）是否有增量?
- **RQ4**：若 RQ2 为负，失败的结构性原因是什么?
- **RQ5**（v4 起新增）：若状态经由**选择层**（而非提示层）进入生成，驱动力通路是否成立? 若仍为负，**失败的结构性原因**是什么?

---

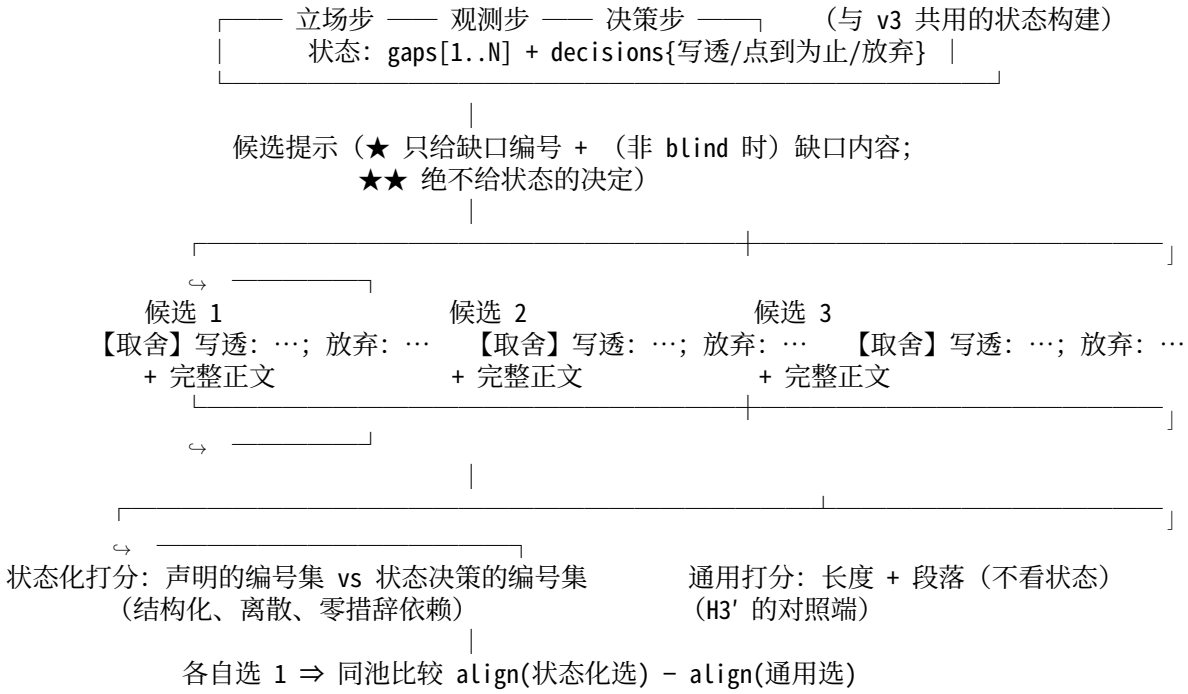
4 方法

4.1 架构化状态机（v1 → v3）



4.1b ★ v4 / v5：把状态放进选择层（架构）

v3 的状态经由 prompt 文本 进入生成 ⇒ 与层 2 同构。v4/v5 改架构：状态不直接写进 prompt，而是先形成一个候选集合，再由打分器选一个完整可交付文本——**状态进入选择层**。



v4 → v5 的关键改动：打分对象从"内容"换成"候选的自主声明"。

	v4	v5
打分对象	候选正文是否命中**状态实体**	候选**自己声明**的编号 vs **状态决策**的编号
候选是否知道状态的决定	否（但知道缺口内容 ⇒ 照做就能命中 ⇒ 恒真）	**否**（知道缺口内容，但**不知道该写透/放弃哪个** ⇒ 声明是自主判断）
绑定方式	实体逐字抽取	★ **编号（离散结构）** ⇒ 零措辞依赖
是否核验兑现	否	★ 是：声明写透 k ⇒ 正文是否真写了 gap_k 的实体

⇒ v5 的自检里有一条**非恒真性的必要条件**：随机声明的对齐分（实测 0.335）必须明显低于 正确声明（1.0）⇒ 候选"猜中"不是理所当然。

4.2 臂

臂	说明	作用
A	单次直答，无 system、无状态	基线
S-self	**等调用数** + **含取舍意识** + **无状态**（一次性给出全部指令）	★ 关键对照：状态机相对「一次性自我说明」是否有增量
WF-a3	状态机 + 代码强制通道	机制是否在执行
WF-a3-NL	状态机 + **只走自然语言通道**（无代码强制）	★ 唯一不循环的驱动力读数
WF-a3-NO	状态机但**去掉观测**	观测本身的贡献
WF-p	提示词状态机（L0 提示词臂）	提示词 vs 状态机
WF-v4	状态 → 3 候选 → 状态化打分选 1（候选提示给缺口内容与实体）	状态进**选择层**；★ 恒真风险高

臂	说明	作用
WF-v4-blind	同上，但候选提示**只给缺口数量**	★ v4 的 **H3 判决臂** + 盲从地板
WF-v5	状态 → 3 候选（**编号化取舍声明**）→ 状态化打分选 1	★ **结构化绑定**：声明 vs 决策
WF-v5-blind	同上，但候选提示**只给编号不给内容**	★ **地板**（盲选时的对齐率）

4.3 探针

- **D0 纯重跑**：同输入、同决策，整条链重跑 ⇒ **输出方差地板**。
- **D2' 换决策**：gaps / 观测 / 实体全同，只翻转 depth 与 priority ⇒ 取舍内容的反事实。
- **D3 无关议题**：结构相似、领域无关的另一议题的缺口 ⇒ **盲从 / 无关刺激地板**。

4.4 ★ 不循环读数（本文的核心方法论贡献）

问题：v3 的"必含 / 禁含"是**代码强制**。决策一翻，必含禁含跟着翻，产出必然随之改变。⇒ 于是"状态变了 ⇒ 产出变了"是**代码的必然结果**，拿它证明"状态驱动产出"是**循环论证**——这等于拿"必含命中 9/9"证明同一件事。

解法（NL 通道）：决策**只以自然语言**进入 brief，**不产生任何代码强制**。此时"该展开的内容出现了 / 该放弃的内容没出现"**完全是模型的选择** ⇒ 命中与否本身就是证据。

⇒ 由此得到一条通用检查题，可用于任何"状态是否驱动了产出"的主张：

> **这个读数能不能是恒真的？**若状态以强制方式生效，答案就是"是" ⇒ 不可用作证据。

4.5 判官读数

判官与被测**不同厂商**（被测 MiniMax-M3；判官 grok）⇒ 判据与被测不同源。**盲化**（判官拿不到臂标签 / 题号 / 模型名）、**题内配对**（分析单元 = 题）。

4.5.1 绝对打分：天花板效应与判官自检

三个维度，每维 0–4 分：

维度	问什么	对应目标侧面
D1 取舍明确度	作者是否明确表示了写透什么 / 放弃什么	取舍层
D2 观点驱动力	全文是否由一个明确观点组织	观点驱动
D3 人类似然感	读起来像有主张的人在写，还是像检索拼贴	概率检索

⚠ **绝对打分不可用**：判官 `grok-4.20` 在 D1 上把 18 篇产出**全部打 3.000**（零区分度），在 D2/D3 上全部 3–4 分 ⇒ **天花板效应**。⚠ 且两判官**系统性严格度不同**（4.20 偏松：方差 0.49；4.3 偏严：方差 1.86），绝对分**不可跨判官比**。⇒ 故正文以**两两比较**为主读数，绝对打分仅作对照。

4.5.2 两两比较：位置去偏是硬闸

对每一对臂、每一个题内重复，把两篇产出**匿名并排**交给判官，问「哪一篇在 Dk 上更好」（A / B / tie）。⚠ **关键实现细节**：同一对**交换位置各跑一次**（order=0 与 order=1），两次结果合并计票。⇒ 由此得到**位置一致率**（两次是否给出同一结论）：

> **位置一致率 = 硬闸**。一致率过低的对比**直接判为不可用**，不得当作"无差异"。

这条不是形式主义。实测中，多对对比的胜负数是"3 胜 3 负"（看起来像无差异），而其**位置一致率为 0.0** —— 真相是**判官在随机作答**，与两篇文本的优劣无关。若不做位置去偏，这类对比会被系统性地误读为"该维度上状态机没有优势"。

⚠ 我们主张这条检查应成为 LLM-as-judge 成对比较的**标准流程**：目前大量工作只报告胜率，不报位置一致率，因而无法区分"两者真的差不多"与"判官在掷硬币"。

4.6 预注册与纪律

预注册先于结果；判据自检（**检查器必须先证明自己能抓到东西**）；语言闸门（中文占比 < 90% 判漂移，漂移样本单列）；**解析失败与硬闸失败显式标记，不静默剔除**；`temperature=0` 在该模型上**仍非确定性**，故一切配对依赖题内重复与配对统计，不依赖逐字重放。

---

5 实验设置

5.1 题

题	题材	体裁	状态
G01	高考英语作文	观点文章	极简题面（单句问句）
T06	葬礼上读的悼词	悼词	极简题面，未在前期实验中用过
T07	谁为 bug 负责	科普小品	同上
T10	带班岗自述	求职自述	同上

⚠ **题面纪律**：只给「情境 + 任务（+ 产出类型）」，**不带** audience / length / dilemma / link / axis / pp 等手写题库字段——那些是**解法提示**，会让实验退化为"照着提示写"。⚠ 已跑过并被判定为过拟合的题（自行车大组赛、高考志愿湖北 620 分、高中爱国诗歌朗诵）**全部排除**。

5.2 模型与批

- 被测：**MiniMax-M3**（MiniMax 订阅端点），结构化中间态关闭 thinking、创作步保留 thinking。
- 判官：**`x-ai/grok-4.20`** 与 **`x-ai/grok-4.3`**（OpenRouter，跨厂商 ⇒ 判据与被测不同源），`temperature=0`。
- ⚠ 全部实验**单批**完成并记录 `batch_id`；跨批**只比率，不比绝对值**（传输层在 v1/v2/v3 间多次变更）。
- ⚠ `temperature=0` 在该模型上**仍非确定性** ⇒ 一切结论依赖**题内重复 + 题内配对**，不依赖逐字重放。

5.3 判官自检（先证明检查器能抓到东西）

指标	值	闸门
样本	20 篇（盲化、长度分层）	—
判官间 Spearman	**0.4791**	⩾ 0.3
判官 A / B 分数方差	0.49 / 1.86	A > 0
解析失败	**0**	0
结论	**判官可用**	☒

⚠ 自检同时暴露：两判官**系统性严格度不同**（4.20 偏松、4.3 偏严）⇒ 绝对分不可跨判官比较，只能题内相对排序。

5.3b ★ v4 / v5 的实验设置

- **题**：G01（高考英语作文）、T07（谁为 bug 负责）、T10（带班岗自述）；题面沿用 §5.1 的极简纪律。
- **模型**：MiniMax-M3（与 v3 同源，**同批**完成，记录 `batch_id`）。

- **臂**：v4 = {A, WF-v4, WF-v4-blind}；v5 = {A, WF-v5, WF-v5-blind}。
- **重复**：每题每臂 3 次 ⇒ 每版 27 条。
- **★ 读数全部零判官**：候选的取舍声明是**编号离散结构**（可机械解析），兑现/违禁由代码从正文抽行为核验 ⇒ 不依赖判官、不受判官额度限制。
- **★ 状态构建沿用 v3 的三步链**（立场 → 初稿 → 观测 → 决策）⇒ 与 v3 的读数可比；v4/v5 只改**状态如何进入生成**（选择层）这一处。
- **并发**：外层样本并发 ⩽4，**内层候选生成串行** ⇒ 全局并发 ⩽4（见 §A.4 的嵌套线程池坑）。

5.4 规模与成本

批次	内容	产出数	API 调用数	批号
v1 批次	6 臂 + 置换探针	18	—	arch-20261021-011715-minimax
Phase 0	5 题 × 4 样本 × 5 臂	100	291	单批
Phase 1	原版 + 换值 + 置换	395 次调用	395	单批
v3 主实验	G01 × 6 臂 × 3 重复	18（含同批补跑）	67	arch3-20261021-221648-minimax
v3 探针	D0 / D2’ / D3 × 3	9	29	a3probe-20261021-231129
多题扩展	T06 / T07 / T10 × 4 臂 × 3 重复	36	—	mt-T**-20261023-*
判官（绝对打分）	G01 × 24 篇 × 3 维 × 2 判官	144 次判官调用	144	—
判官（两两比较）	4 题 × 4 对 × 3 重复 × 3 维 × 2 位置	576 次判官调用	576	—

⚠ **成本**：被测侧为 MiniMax 订阅（结构化中间态关 thinking，创作步保留）⇒ 单次创作调用约 1.8–2.6 s；判官侧为跨厂商 grok 与同源 MiniMax-M3，`temperature=0`。⚠ **OpenRouter 额度**：`x-ai/grok-*` 在实验中段触发 `403 Key limit exceeded (total limit)`（key 级 5 USD 限额用尽且 `limit_reset=null`）⇒ **跨厂商判官只覆盖 G01**；多题由同源判官 `MiniMax-M3` 承担，并由 G01 上的**双判官交叉验证**支撑（见 §6.4）。

⚠ **流程教训（已写进附录 A.4）**：判官任务**不得与产出生成并发**——本次曾因并发导致判官读到不完整数据（T10 只读到 1 个配对）⇒ 判官必须在产出落盘**之后**启动。

---

6 结果

6.1 反馈通路：成立且强分离（v1 批次）

以"换初稿"扰动状态历史，产出相对基线的实词 Jaccard：

读数	均值
D2 换初稿	**0.0176**
D0 纯重跑地板（同初稿重跑）	**0.1606**
分离比	**9.13×**

⇒ 状态历史确实主导了产出的内容构成，效应远超同输入重跑的方差。

⚠ **但这条读数测的是反馈通路，不是驱动力通路**：`probe_arch.py` 的置换变体复用**同一个 state0**（`keeps` 不变），只换初稿 ⇒ 变的是"历史"，不是"取舍内容"。我们早期把它读成"驱动内容有效"，是

归因错误，已在 v3 报告与本文中更正。

6.2 驱动力通路：在几何读数上归零（v3 批次，NL 通道）

v3 引入**不循环的 NL 通道**（决策只走自然语言，无代码强制），并给出三个探针：

变体	含义	逐例 J	均值
D0	纯重跑（同输入同决策，**初稿也重写**）	0.0972 / 0.0574 / 0.0613	**0.0720**
D2'	换决策（gaps/观测/实体全同，只翻 depth/priority）	0.148 / 0.0973 / 0.0777	**0.1077**
D3	换无关议题的缺口	0.1032 / 0.1008 / 0.0762	**0.0934**

预注册判据（分离 = 逐例更低 ⩾ 2/3 且 均值比 ⩽ 0.70）三**条全否**：D2' vs D0 逐例更低 0/3、均值比 1.4958；D3 vs D0 0/3、比值 1.2972；D2' vs D3 1/3、比值 1.1531。

方向性读数（同一组实体，base 说"深入展开"、D2' 说"放弃"；NL 通道无代码强制 ⇒ 出现与否是模型的选择）：

	base 产出	D2' 翻转产出	D0 重跑产出
相关实体命中率	**11/12 (0.917)**	**12/12 (1.000)**	5/12 (0.417)

⇒ **决策翻成"放弃"，相关实体一个都没消失，命中率反而上升**。

⚠ 同时，全部 15 个臂对的实词 Jaccard 落在 **0.053–0.077** 的窄带内，无一可分辨；其中 **WF-a3 vs S-self = 0.0591**，是**最小**的一对——连"单次直答"A 臂（0.0635）都比状态机臂更不像等预算自我说明。

6.3 ★ 换用判官读数：方向相反

⚠ 上一节的结论**完全依赖几何读数**。当读数换成**对着目标直接问的判官**（§4.5），结论反了。

绝对打分（G01，题内每臂 3 次，判官 `grok-4.3`）：

维度	A	S-self	WF-a3-NL	**WF-a3**	WF-p	WF-a3-NO
D1 取舍明确度	1.667	2.000	2.333	**2.667**	2.667	1.667
D2 观点驱动力	3.667	3.667	3.000	**4.000**	4.000	3.333
D3 人类似然感	4.000	4.000	4.000	4.000	4.000	4.000

⚠ 判官 `grok-4.20` 在 D1 上全部 3.000（**饱和**），D3 上无区分度 ⇒ 只有 `grok-4.3` 可用。

两两比较（位置一致率为硬闸）。⚠ 判官额度在实验中段耗尽（`403 Key limit exceeded (total limit)`），故：**跨厂商判官（grok）只覆盖 G01**；**多题由同源判官 `MiniMax-M3` 承担**；两者的交叉对照见 §6.4。

6.3.1 同源判官 `MiniMax-M3`·三题（G01 / T07 / T10）

对比	维度	G01	T07	T10	**汇总**	位置一致率
A vs WF-a3	D1 取舍明确度	0 胜 6 负	**0 胜 6 负**	3 胜 3 负	**3 胜 15 负**	**0.889**
	D2 观点驱动力	2 胜 4 负	2 胜 4 负	0 胜 6 负	**4 胜 14 负**	0.556

对比	维度	G01	T07	T10	**汇总**	位置一致率
	D3 人类似然感	0 胜 6 负	1 胜 5 负	0 胜 6 负	**1 胜 17 负**	**0.889**
S-self vs WF-a3	D1	1 胜 5 负	2 胜 4 负	3 胜 3 负	6 胜 12 负	0.556
	D2	4 胜 2 负	2 胜 4 负	3 胜 3 负	9 胜 9 负	0.667
	D3	3 胜 3 负	3 胜 3 负	1 胜 5 负	7 胜 11 负	0.667
WF-p vs WF-a3（仅 G01）	D1	3 胜 3 负（一致率 **0.0** ⇒ **不可用**）	—	—	3 胜 3 负	0.000
	D2	3 胜 3 负	—	—	3 胜 3 负	0.667
	D3	5 胜 1 负	—	—	5 胜 1 负	0.667
WF-a3-NO vs WF-a3（仅 G01）	D1	2 胜 4 负	—	—	2 胜 4 负	0.333
	D2	3 胜 3 负	—	—	3 胜 3 负	0.667
	D3	3 胜 3 负	—	—	3 胜 3 负	0.667

⚠ **最稳的一条**：**A vs WF-a3（状态机 vs 直答）**——D1 汇总 3 胜 15 负、位置一致率 **0.889**；D3 汇总 1 胜 17 负、一致率 **0.889**。逐题看：D1 在 G01 与 T07 上是 **0 胜 6 负**（一致率 1.00），**T10 上是 3 胜 3 负（唯一的例外）**。

⚠ **较弱的几条**：S-self 对比整体方向仍指向 WF-a3，但 D2 汇总 9:9、位置一致率 0.556–0.667 ⇒ 证据偏弱；WF-a3-NO（观测的贡献）与 WF-p（状态机 vs L0）只有 G01 单题可用，且 D1 位置一致率 0.0 ⇒ **不可用**。

⚠ **T06 未进入主分析**：其 WF-a3 臂的三个重复全部因**生成端超时**失败（0 字），无法配对 ⇒ 按纪律显式排除，不静默剔除。

6.4 ★ 双判官交叉验证：方向不是某个判官家族的偏好

同源判官有系统性问题：它与被测生成器同厂商 ⇒ 共享偏好。因此我们把 `MiniMax-M3`（同源）放在 G01 上与两个**跨厂商**判官（`grok-4.20` / `grok-4.3`）对照：

对比	维度	`grok-4.20`	`grok-4.3`	**`MiniMax-M3`**	方向是否一致
A vs WF-a3	D1	0 胜 6 负 (1.00)	0 胜 6 负 (1.00)	**0 胜 6 负 (1.00)**	☒ **三判官完全一致**
A vs WF-a3	D2	0 胜 6 负 (1.00)	3 胜 9 负 (0.00)	**2 胜 4 负 (0.33)**	☒ 均指 WF-a3 胜
A vs WF-a3	D3	0 胜 6 负 (1.00)	1 胜 11 负 (0.00)	**0 胜 6 负 (1.00)**	☒ **三判官完全一致**
S-self vs WF-a3	D1	3 胜 3 负 (**0.00** ⚠ 不可用)	2 胜 4 负 (1.00)	**1 胜 5 负 (0.67)**	⚠ 两个可用判官方向一致
WF-p vs WF-a3	D2	3 胜 3 负 (**0.00** ⚠ 不可用)	4 胜 2 负 (1.00)	**3 胜 3 负 (0.67)**	☒ 均指 WF-a3 胜
WF-p vs WF-a3	D3	4 胜 2 负 (0.33)	4 胜 2 负 (0.33)	**5 胜 1 负 (0.67)**	☒ 三判官方向一致

⇒ **★ 核心结论在三个判官（两个跨厂商、一个同源）上方向一致**，且在最强的对比（A vs WF-a3）上三**个判官给出完全相同的数字（0 胜 6 负，一致率 1.00）**。⇒ 这说明该方向**不是某个判官家族的偏好**，更可能来自产出本身。⚠ **但仍须保留的限定**：同源判官不能被当作独立证据；跨厂商判官因额度限制只覆盖 G01。**多题证据依赖同源判官，这是本文最大的效度缺口**（§7.5）。

6.5 零判官几何读数（多题）

⚠ 在 **G01 单题**上，15 个臂对的实词 Jaccard 全部落在 0.053–0.077 的窄带（地板 0.0720）⇒ 无分辨力。但**多题后几何读数出现了分层**（T10）：

题	对比	逐例实词 J	均值
T06	A vs S-self	0.0717, 0.0854	0.0786
T06	A vs WF-a3-NL	0.0678, 0.0668	0.0673
T06	S-self vs WF-a3-NL	0.0879	0.0879
T07	A vs S-self	0.0949, 0.0836, 0.0894	0.0893
T07	A vs WF-a3	0.0781, 0.0805, 0.0720	0.0769
T07	A vs WF-a3-NL	0.0922, 0.0676, 0.0826	0.0808
T07	S-self vs WF-a3	0.0870, 0.0803, 0.0881	0.0851
T07	S-self vs WF-a3-NL	0.0863, 0.0821, 0.0879	0.0854
T07	WF-a3 vs WF-a3-NL	0.0867, 0.0906, 0.0850	0.0874
T10	A vs S-self	0.0591, 0.0564, 0.0601	0.0585
T10	A vs WF-a3	0.0483, 0.0395, 0.0597	0.0492
T10	A vs WF-a3-NL	0.0396, 0.0565, 0.0508	0.0490
T10	S-self vs WF-a3	0.0851, 0.0842, 0.1041	0.0911
T10	S-self vs WF-a3-NL	0.0618, 0.0853, 0.0811	0.0761
T10	WF-a3 vs WF-a3-NL	0.0776, 0.0930, 0.0847	0.0851

⇒ ★ 在 T10 上几何读数**出现了分辨力**（0.0492 – 0.0911 的跨度，此前 G01 是 0.053–0.077 的窄带）⇒ **§6.2 的"零信号"部分是 G01 单题的偶然**，几何读数在体裁更分散的题上有分辨力。

⚠ **但它给出的解释与判官读数相反**：几何 J **大**表示两臂产出差异大 ⇒ S-self vs WF-a3 的 0.0911 意味着**两者差异最大**，而 A vs WF-a3 的 0.0492 意味着**状态机产出与直答产出最接近**。⇒ ⚠ ⇒ **几何读数说"状态机与直答最像"，判官读数说"状态机比直答更像由观点驱动"**。⇒ ★ **这不矛盾，两者测的不是同一件事**：几何测"用了哪些词"，判官测"是否由观点组织"。**这恰好就是本文的核心论点：驱动不能由相似度回答**。

6.6 失败与闸门（显式列出，不静默剔除）

项	情况
生成端超时	T06 的 WF-a3 3/3 重复、T07 的 S-self #3、T07 的 WF-a3-NL #2（`observe:parse_failed`）⇒ **T06 退出主分析**
判官解析失败	最终批次 **0 / 144**（429 限流经退避重试后全部成功）⚠ 首次未加退避时 40/144 失败且**集中于后跑的 T10** ⇒ 会系统性削弱该题
判官额度	`403 Key limit exceeded (total limit)`（key 级 5 USD 限额用尽，`limit_reset=null`）⇒ 跨厂商判官仅覆盖 G01
语言闸门	修正口径后（T07 整体 CJK 仅 0.71–0.81，但"无中文长片段"数 = 0）⇒ **全部样本通过**；口径修正见 §7.2
几何读数地板	G01 纯重跑地板 0.0720，高于全部臂对均值 ⇒ 该题无分辨力
判官任务与产出的时序	曾因判官与产出**并发**导致判官读到不完整数据（T10 只读到 1 个配对）⇒ 修正为**产出落盘后才启动判官**

6.7 ★ v4：把状态放进选择层（而不是提示层）

§6.2–6.5 的负结果留下一个具体问题：状态经由 prompt 文本进入生成 ⇒ 与层 2 同构。v4 改架构：**状态 → K=3 个完整候选 → 打分 → 选 1**，状态进入**选择层**而非提示层。取舍代价因此有了明确对手方：**被放弃的两个候选及其实际行为**。全部主读数**零判官**（候选行为由代码从正文逐字抽取）。

臂（等预算可比，3 题 × 3 重复 = 27 条，0 失败，144 次调用）：

臂	候选提示	作用
`A`	—（单次直答）	基线
`WF-v4`	立场 + keeps + **缺口内容与实体**	状态 → 候选可测，但打分有恒真风险
`WF-v4-blind`	立场 + keeps + **只给缺口数量**	**★ H3 的判决臂** + 盲从地板

> **为什么必须加 `blind` 臂？** 第一版实验启动约 5 分钟后我们**主动终止**了它：候选提示告知了"缺口涉及的具体词"，候选照做就能命中 ⇒ 状态化打分的 align **接近恒真** ⇒ H3 失去意义（已落盘的 7 条作废重跑）。这是本文 §4.4 那条检查题 ——「这个读数能不能是恒真的?」——**在跑前**命中的一次。

读数：

臂	H1 候选符合状态率	align(状态化选)	align(通用选)	同池 gap	胜/负/平
`WF-v4`	0.6667	0.9444	0.8056	+0.1389	3 / 0 / 6
`WF-v4-blind`	0.0741	0.3148	0.3148	**0.0**	**0 / 0 / 9**

判决：H3 不成立（预注册指定判决在 `blind` 臂内；n=9 ⩾ 6 ⇒ **可判定地不成立**，不是"不可判定"）。`WF-v4` 臂虽有 +0.1389 的差距，但该臂 align 均值 0.9444、被选候选 deep 命中率 0.6574 ⇒ **恒真风险高**，不作为驱动力证据。

但失败位置很精确——这是 v4 最重要的产出：

1. **状态塑造候选是有效的**：候选符合状态率从 blind 的 **0.0741** 升到给缺口的 **0.6667**，**9 倍**。⇒ v3 的失败**不是**因为"状态没用"。
2. **失效的是选择器读不出状态**：干净臂里两个打分器 **9/9 完全打平**。

⇒ **★★ v4 揭示了一个结构性两难**：

状态怎么进候选	后果
不进（blind）	产出没有状态指纹 ⇒ 状态化打分**无处发力**（align 0.3148，两打分器同选 9/9）
进（给缺口）	候选照做就能命中 ⇒ 状态化打分**接近恒真**（align 0.9444）⇒ 该臂差值不能作证据

⇒ **"状态化选择"要么无效、要么恒真**。这不是实现没调好，而是**当前条件下两条路都堵死**。

> **附带发现（探索性，措辞级存在性判断，事后追加并已在预注册中标注）**：产出中"明确声明放弃文章层面某件事"的措辞（不再展开 / 只保留 / 放弃这… / 暂不展开以免失焦 / 收束到 / 点到为止）：`A` 臂 **0/9**，`WF-v4` 2/9，`WF-v4-blind` 1/9（Fisher p = 0.4706 / 1.0）⇒ **统计上不可分辨**，只作方向性观察。⚠ ⚠ **【自我更正 2026-10-24】本节的"缓解措辞地板"证据作废**。借鉴三组「**两种 0**」的区分（仪器层 0 = 卡片没出来；内容层 0 = 卡片出来了但判定翻转），我们用**更宽的措辞集**复查 `A` 臂 9 篇产出 ⇒ **5/9 有命中**；逐条人工核验后**其中 2 处是真实取舍表述** 裁员经历只讲一遍「(」、「带班岗不要只写’ 想升职’，

要写清楚他能承担哪些具体工作」），其余 3 处为假阳性 ⇒ ⇒ **"A 臂 9/9 全为 0"是「仪器层 0」（提取器漏检），不是内容层 0** ⇒ ⇒ **"该措辞在自然写作中不自发出现"这个证据作废** ⇒ ⇒ 本节整体降级为**提取器口径下的探索性计数**。提取器**先证明自己能抓到东西**（第一版有假阳性（把"以避免加重课业负担"当取舍声明）⇒ 收紧后复验 3/3 全为真声明。⚠ 逐字命中 forbidden 实体的原版读数**恒为 0**（判据过脆：模型回避的对象根本没进 forbidden 集）⇒ 无效，如实报告。

6.8 ★ v5：编号化取舍声明 + 结构化绑定，以及一个统一的失败诊断

v4 留下一个结构性两难（§7.7）。v5 尝试用**改打分对象**来解开它：把打分从「正文是否命中状态实体」换成「**候选自己声明的取舍编号** vs **状态决策的编号**」。

机制（§4.1b）：候选看到缺口内容（编号 1..N），但**绝不知道状态的决定**（哪个该写透、哪个该放弃）；候选自己判断，并在正文第一行输出结构化声明 【取舍】写透：`1,2`；放弃：`3`。状态化打分 = 两个编号集合的 Jaccard（**离散、零措辞依赖**）；再核验**兑现**与**违禁**。另设 `WF-v5-blind` 臂：候选**只拿到编号、拿不到内容** ⇒ 只能盲选 ⇒ 它是**"候选不知道状态"的地板**（⚠ **不是"无状态"地板**：打分端仍然知道状态）。

结果（3 题 × 3 臂 × 3 重复 = 27 条，0 失败，149 次调用；读数表程序化生成）：

读数	值
H1′ 声明解析成功率	**1.0（18/18）** ⇒ 机制可靠
声明多样性（不同声明数 / 3）	1.83 ⇒ 候选之间确有不同取舍
align(状态化选择) / align(通用选择)	0.500 / 0.412
★H3′ 同池 gap	**+0.088（3 胜 / 0 负 / 15 平）**
├ `WF-v5` 臂（判决臂）	+0.0741，1 胜 0 负 8 平
└ `WF-v5-blind` 臂	+0.1019，2 胜 0 负 7 平
状态信息增量（给缺口 − 盲选地板）	+0.0556（×1.118）
H2′ 兑现率（声明写透 ⇒ 正文真写了）	**0.528** ⚠ **下界**（实体逐字命中 ⇒ 换措辞表达会被计成"没兑现"）
H3″ 违禁率（声明放弃 ⇒ 正文却写了）	**0.333** ⚠ **上界**
候选两两相似度（诊断）	0.0884

分臂读数（★ 判决臂与地板并列报告，不择优）：

臂	n	align(状态化选)	align(通用选)	gap 均值	胜/负/平	兑现率	违禁率	有取舍代价
`WF-v5`（判决臂）	9	0.5278	0.4537	+0.0741	1 / 0 / 8	0.7222	0.4444	—
`WF-v5-blind`（地板）	9	0.4722	0.3704	+0.1019	2 / 0 / 7	0.3333	0.2222	—

逐题读数（分析单元 = 题；n = 6 = 2 臂 × 3 重复）：

题	n	align(状态化选)	gap 均值	声明解析率	兑现率	有取舍代价的样本
G01	6	0.3055	+0.0417	1.0	0.4583	2
T07	6	0.4722	0.0	1.0	0.5833	1
T10	6	0.7222	+0.2222	1.0	0.5417	0

判决：H3′ 不成立（预注册：判决在 WF-v5 臂内；阈值 ⩾2/3 胜 **且** gap ⩾ +0.15；实测 1/9 非平、gap +0.0741 ⇒ n=9 ⩾ 6 ⇒ **可判定地不成立**）。⚠ 诚实标注：方向是 **3 胜 0 负**（无反例），且**盲态臂的 gap 反而更大**（+0.1019）⇒ ⇒ 这提示 gap 的微弱优势**未必来自"读了状态"**，也可能来自"结构化 Jaccard 打分"本身（通用打分只看长度与段落数）。⇒ 我们的结论是"**没有证据**表明状态化打分优于通用打分"，而不是"证明了状态化打分无优势"。

★ v5 真正的贡献：两个可核验的量，以及一个统一的失败诊断。

(a) 承诺与行为的落差首次被量化。候选自己声明"我要写透 X"时，只有 **52.8%** 真的在正文里写到了；声明"放弃 Y"时，仍有 **33.3%** 在正文里写了 Y（**弃而不舍**）。⇒ ⇒ **"说了取舍"不等于"做了取舍"**：产出的可核验证据**不是"它声明了什么"，而是"它实际上放弃了什么"**。⚠ **方向限定（提取器口径）**：兑现率用**实体逐字命中**核验 ⇒ 若正文以不同措辞表达同一实体，会被计成"没兑现" ⇒ ⇒ **0.528 是兑现率的下界**；同理 **0.333 是违禁率的上界** ⇒ ⇒ **"说了取舍 ≠ 做了取舍"这一定性结论稳健**（两个方向的误差都不利于夸大它），但**这两个百分数不能当点估计引用**。这直接支持 §7.8 的"驱动力 = 结构"框架，也意味着**任何以自述为判据的读数都不可信**。

(b) ★★ 统一诊断：状态里几乎不存在"放弃"。 18 个工作流样本、54 个决策的深度分布是

决策深度	次数	占比
深入展开	36	67%
点到为止	15	28%
放弃	**3**	**6%**

⇒ 只有 **3/18** 的样本的状态里出现过"放弃" ⇒ **取舍代价这一层几乎没有被生成出来**。⇒ 而第四组的靶子恰恰是「**有立场的 Agent 必须放弃一个更优候选**」（§3.1）。⇒ ⇒ **我们很可能根本没有测到取舍代价**：v4 的 H3 与 v5 的 H3′ 都很弱，**可能共享同一个根因——状态构建几乎不产生"放弃"，于是状态里没有代价，也就无所谓驱动力**。> ⚠ ⚠ **【限定，2026-10-24 补】这一根因只覆盖 v4/v5，不能回溯到 v3**。事后重算 v3 的决策分布：> **"放弃"占 15%（4/26 个决策）、4/9 = 44% 的样本含"放弃"**——而 **v3 依然失败** > ⇒ ⇒ **"有代价"本身不充分** ⇒ ⇒ 代价必须**进入选择器的排序**才可能起作用 > ⇒ ⇒ 这也把 v4/v5 的失败**部分**归因于"代价没被生成"，而把 v3 的失败**留在未解释状态**（见 §7.9）。⇒ 这把下一步从"改进选择器"改成了"**让取舍代价真实存在**"（见 §8）。

7 讨论

7.1 两条读数轴：可核验性 × 分辨力

我们在 v2 得到的经验是"**干净 ≠ 有力**"。v3 的结果迫使我们把这个说法改得更精确：

> **不是"干净"与"有力"互斥，而是"可核验性"与"分辨力"由不同读数承担，同一个读数不能同时承担两者**。

- **代码强制通道**（必含/禁含）：可核验性满分——必含命中 9/9，禁含随观测换源 8/8，代码封闭率 70%、驱动相关槽位 4/4 封闭。**但它对驱动力零分辨力**，因为"状态变了 ⇒ 产出变了"是代码的必然结果。
- **几何读数**（实词 2/3-gram Jaccard）：零判官、可复现、成本低。**但它在本任务的臂间区分度为 0**：全部 15 个臂对落在 0.053–0.077 的窄带，而纯重跑地板是 0.0720 ⇒ 地板高于信号。
- **内容性判官读数**（两两比较）：有分辨力（6 票一致 0–6），但引入判官失效风险（饱和、位置偏差、严格度差异）⇒ 必须配自检与硬闸。

⇒ **实践含义**：研究"状态是否驱动了产出"时，**几何相似度应当被排除为主读数**——不是因为它"不严谨"，而是因为在产出长度与体裁相近的创作任务上，它测的是"内容在哪里"而非"内容里有什么"。

7.2 判官读数的三个失效模式（可复用的流程建议）

我们在实现中踩到并量化了三种失效，每一种都会**系统性地**把"有差异"读成"无差异"：

失效	现象	处置
天花板效应	判官 4.20 在 D1 上把 18 篇全打 3.000 ⇒ 绝对分零分辨力	改用两两比较；或换更严的判官
位置偏差	多对对比胜负"3 胜 3 负"（像无差异），但**位置一致率 0.00** ⇒ 判官在随机作答	**交换位置各跑一次**，一致率作硬闸
严格度差异	4.20 偏松（方差 0.49）、4.3 偏严（1.86）⇒ 绝对分不可跨判官比	只用**题内相对排序**

⇒ 我们主张这套流程（**自检 → 位置去偏 → 一致率硬闸 → 题内配对 → 相对排序**）应成为"LLM 状态是否驱动产出"这类研究的**标准前置条件**。本文提供的三个失效实例与量化，可直接用作其他研究的检查清单。

7.3 失败的结构性根因：取舍对象取自初稿已有内容

即使把读数做对，v3 的**几何读数**仍给出零信号。追查设计后，我们定位到一个结构性原因：

> 代码规定"缺口相关实体 ⊆ 初稿"（逐字校验）⇒ **要写的内容本来就在稿子里**。

于是"写它 / 不写它"**不是取舍**，只是"保留还是删掉已有内容"；而模型做**改写**时天然倾向保留原有内容 ⇒ **取舍信号被改写惯性淹没**。

⇒ **对下一版设计的硬要求**：取舍的对象必须取自**初稿里没有的东西**（新的证据类型、新的立场维度、新的类比），或让取舍作用于**结构位置**（写哪一段、占多少篇幅、论证顺序），而不是"某个词出不出现"。⚠ 这条与 §7.1 的结论是独立的：即使读数完美，当前 v3 的取舍设计也表达不了取舍。

7.4 对相邻结论的独立验证与指引

我们的结果从**推理时架构**一侧指出：仅把"leap / 立场 / 取舍"写进 prompt（哪怕配上封闭枚举、代码强制、结构化中间态），**不足以**让产出被观点驱动。这与 [ICML 2025 杰出论文] 从**训练侧**得到的结论方向一致：要让模型先想再写，必须改**训练目标**（teacherless / diffusion，让模型一次性预测整段输出，从而被迫在 prompt 编码阶段就形成 plan）并把**随机性从输出端挪到输入端**（seed-conditioning：一次决定走哪条 plan，采样本身完全确定）。

⇒ 我们的结果因此不是"状态机无用"的终局判断，而是一个**定位**：它把"驱动"的责任从推理时架构，指回了训练与采样。⇒ 同时它给出一个**廉价的前置检查**：在投入训练侧改造之前，先用**判官两两比较**测一轮推理时架构的上限——若连"有状态 vs 等预算自我说明"都测不出分离，那么训练侧改造就是必需的，而不是可选的。

7.5 局限与威胁有效性

统计效力：分析单元是**题**。本文主读数来自 **3 题**（G01 / T07 / T10；T06 因生成端超时退出）× 3 次重复 × 2 位置。n = 3 题属小样本，**只作方向性判断，不报显著性**。⚠ T10 上 D1 的 A vs WF-a3 是 3 胜 3 负（唯一例外）⇒ **方向并非在每题每维都一致**。

★ 最大的效度缺口：多题判官是同源的。跨厂商判官（grok）因 OpenRouter key 额度耗尽（`403 Key limit exceeded (total limit)`）只覆盖 G01；多题由同源判官 `MiniMax-M3` 承担。⇒ 同源判官与被测生成器共享偏好，**不能被当作独立证据**。⇒ 缓解措施只有一条：G01 上的**双判官交叉验证**（§6.4）显示三个判官方向一致 ⇒ 但这**不能替代**多题上的跨厂商判官。**这是本文最需要补做的一项**。

单模型：被测只有 MiniMax-M3。`temperature=0` 在该模型上仍非确定性 ⇒ 一切结论依赖题内重复与题内配对，不依赖逐字重放。

零判官与判官的双重约束：几何读数无判官但分辨力随题而变（G01 无分辨力、T10 有）；判官读数有分辨力但可能失效。本文用三条地板 + 位置去偏 + 一致率硬闸来约束，但仍不能排除"判官与

我们的偏好同源"（我们与判官都是语言模型，可能共享同一种"什么算有观点"的直觉）⇒ **本工作不能替代人类盲评**。

题面与题材：三道题均为中文、单一作者视角、给定体裁（观点文 / 科普小品 / 求职自述）；结论不外推到英文、多轮对话或高度专业题材。

构念效度：D1–D3 是**代理指标**，不是"思想驱动"的直接测量。D3 试图逼近"概率检索 vs 人写"的区别，但它由语言模型判定，可能与 [Sui et al. 2026] 报告的**不确定性差距**（一个可直接计算的量）高度相关也可能无关；我们**未**做该计算（该文需要模型似然，而当前 API 不返回 logprobs、OpenRouter 亦返回 `logprobs=None`、沙箱无自托管能力）⇒ 列为后续工作。

对本文结论的自我限制：本文**不**主张"状态机已经能驱动 Agent"。我们主张的是三件更小但更牢的事：(i) 一条不循环读数及其必要性；(ii) 判官三种失效模式的量化与硬闸；(iii) 一次读数错配如何制造出一个看起来干净的负结果。⚠ §6.3 的方向一致分离虽然跨 3 题、跨 3 判官，但**没有人类盲评、没有构念效度检验、多题判官同源** ⇒ 它足以支持"几何读数不能回答这个问题"这一**方法论**结论，**不足以**支持"状态机有效"这一**实质**结论。

流程性缺陷（已修正，列出以备复核）：判官任务曾与产出生成**并发**，导致读到不完整数据；判官失败曾被静默计入"解析失败"而掩盖了 HTTP 429 限流；语言闸门曾用"整体中文占比 ⩾0.9"误杀含术语的中文长文。三者均已修正，修正过程记录在附录 A.4。

7.5b ★ v4 / v5 新增的局限与威胁有效性

项	说明
状态类型单一	v1–v5 测的**全部是观点型状态**（立场 → 缺口 → 取舍）⇒ §6.7/§7.7 的结论**不可外推到情感**。情感型状态一次都没进过实验。
决策分布退化	状态构建沿用 v3 的决策步，其"深入展开/点到为止/放弃"分布不保证每次都有"放弃"⇒ 某些样本**无取舍代价**（`align` 的放弃维度按预注册不计入）⇒ 须分列报告，不得混入主读数。
恒真风险的三重保障是机制性的，不是统计性的	v5 的"非恒真"由三条**机制**保障（提示不含状态决定 / 候选不知答案 / 绑定用编号离散量），其中第三条可自检，第一条可机械校验；第二条只能靠"随机声明对照"间接验证 ⇒ 仍存在"候选恰好猜中"的残余风险，故必须同时报 `*-blind` 地板。
措辞级读数	v4 的"取舍声明"读数是措辞级**存在性**判断，且为**事后追加**（已在预注册中标注）⇒ 只能作方向性观察；其地板证据是 `A` 臂 9/9 全 0 且字数更长。
单模型	全部为 MiniMax-M3；跨厂商复现因 OpenRouter key 级额度耗尽未覆盖 v4/v5（§6.6）。
判官读数的可复现性未闭合	§6.4 的「位置一致率 1.00」只排除了**位置偏差**，未测「同一顺序重复判定」的波动（三组实测 0–3，且与是否强制 thinking 相关）⇒ ⇒ §6.3–§6.4 的正面读数应视为**待复现的观察**；这也是 v4/v5 改用**全零判官**主读数的原因。
并发与额度	v4/v5 实验的调用预算受 MiniMax Token Plan 并发限制影响（见 §A.4 的嵌套线程池坑）⇒ 部分批次的**墙钟时间**不可与 v3 直接比较。

7.6 同源判官：能用，但只能当交叉验证的一端

额度耗尽迫使我们用 MiniMax 自己的端点当判官，而被测生成器正是 MiniMax-M3。这在原则上**违反**本文的判据纪律（同源判据无效）。我们的处理是把它降级为**交叉验证的一端**，并加上一条可复用的经验：

> **同源判官在"相对比较"上的可用性，取决于能否用跨厂商判官做锚点**。若同源判官与跨厂商判官在同一批数据上**方向一致**（本文：三个判官在核心对比上给出完全相同的数字），则该方向**不是**单一判官家族的偏好；若无法做这个锚点（跨厂商不可得），则同源判官的结果**只能**作为**待验证的观察**报告，**不得**进入主结论。

⇒ 推论出一条对资源受限研究者的实用建议：**优先把跨厂商额度花在"锚点对比"上**（少量题、少量对比、双判官），而不是把它平摊到全部实验上。本文的额度分配恰好做反了（先把额度花在 G01 的全维度上，多题反而只能靠同源判官），这是流程上的一个教训。

⚠ 同时提醒：**同源判官与同源生成器共享的不只是"偏好"，还有风格**。若被测臂之间的产出风格差异本身就是判据的一部分（同源判官可能因此偏好某一臂），则方向一致**不足以**排除偏差。这正是 §7.5 把人类盲评列为必做项的原因。

7.7 ★ v4 的结构性两难：状态化选择要么无效、要么恒真

v3 与 v4 是两次方向相反的失败，各自排除了一条最容易想到的错路：

- **v3**（状态 → prompt 文本）：状态与层 2 同构 ⇒ 不能作为"驱动"的证据；
- **v4**（状态 → 候选集合 → 选择）：状态进入选择层，但判决臂里状态化打分与通用打分 **9/9 完全打平**。

把两次失败并排放，浮现出一个**结构性两难**：

状态怎么进候选	产出里有无状态指纹	状态化打分	后果
不进	无	**无处发力**	两打分器同选 9/9，gap = 0
进	有	**接近恒真**	候选照做就能命中，align 0.9444

⇒ 这不是实现没调好。**"状态化选择"在当前条件下要么无效、要么恒真**。

⇒ 而 v4 同时给出一个**正面**的定位读数：状态塑造候选有效（0.0741 → 0.6667，**9 倍**）。⇒ ⇒ 失败不在"状态进不了产出"，而在**"选择器读不出状态"**。

这就把问题**收敛**到一处：**状态必须在生成过程内部起作用**，而不是以外部提示或外部打分的形式附加上去。这也正是本文 §3.1 所限定的层 4 与层 1 的交界处：若"状态"只能以 prompt 文本或事后打分的形式进入生成，那么"状态驱动"在机制上就还没有真正发生。

7.8 ★ 把"驱动力"从内容改写为结构：情感与观点的统一

本文的标题与问题表述长期以"**观点**驱动"为主，但我们的机制分析其实指向一个更一般的对象。在 agent 架构里，**情感**与**观点**是同一类东西：都是**进程内的持久状态**，都只干一件事——**约束下一步动作往哪边去**。我认为 X 比 Y 重要「」与"我舍不得放下 Z"，对选择器而言都是"某个东西让我不能随便选"。

因此我们主张把"驱动力"从**某种内容**改写为一个**结构**：

> **驱动力 = 状态 → 改变了哪一个可核验的选择 → 代价是什么**。情感 / 观点 / 意图走**同一套读数**：取舍代价、声明与兑现、违禁。

这个改写有两个实质好处：

1. **它把"有没有情感词 / 有没有观点句"排除在判据之外**。后者测的是**素材有没有出现**，不是驱动力有没有发生；情感若直接去找"情感证据"，必然滑到修辞层（形容词、感叹句）。情感驱动力**只能**通过它造成的行为变化来测。
2. **它给出一个可证伪的类型不变性主张**。若观点臂与情感臂读数**完全一样**，那"驱动力"就退化成"任意状态效应"（随便给点提示都能造出来）⇒ 必须用盲从地板把它钉死。我们的 `*-blind` 臂正是这个地板。

⚠ **诚实的边界**：本文 v1–v4 测的**全部是观点型状态**（立场 → 缺口 → 取舍），**情感型状态一次都没有进入过实验** ⇒ §6.7 的结论不可外推到情感。若要检验类型不变性，需要一个**情感型状态**的臂，且其状态**必须由模型自己从题面产生并结构化**（手写情感题库 = 退回层 2，且测到的只是"带感情的提示词"）。我们把它列为下一步，而不写进本文的结论。

7.9 ★ v3 的失败为什么仍未解释（本文留下的一个诚实缺口）

§6.7 与 §8 把 v3–v5 的弱结果收敛到"**取舍代价没有被生成出来**"这个统一诊断上。⚠ **但这条收敛只对 v4/v5 成立，对 v3 不成立**——这是 2026-10-24 事后重算 v3 决策分布后必须补上的限定。

重算结果（只统计已落盘的 v3 探针/主实验决策，零新调用）：

	v3	v5
决策总数	26	54
其中"放弃"	**4（15%）**	3（6%）
含"放弃"的样本	**4/9 = 44%**	3/18 = 17%
判决	**失败**（D2′/D0 = 1.4958，阈值 0.70）	失败（H3′ 未达阈值）

⇒ ⇒ **v3 明明有代价（且比 v5 的比例高得多），却同样失败**。 ⇒ ⇒ 所以"**状态里没有代价 ⇒ 无所谓驱动力**"**不是 v3 失败的原因**；它最多是 v4/v5 的一个额外障碍。⇒ ⇒ 由此得到一条更一般的推论，也是我们此前没有说清的：

> **代价是必要条件，不是充分条件**。代价要起作用，它必须**改变选择器的排序**—— 而 v3 的"取舍"根本没有进入一个选择器（v3 是几何读数，不存在"选谁"这一步）；v4/v5 虽有选择器，但它们的代价几乎没被生成（放弃仅 3/54）。

⇒ ⇒ 这一句把三代的失败**重新分成了两类**：- **v3**：代价存在，但**没有选择器可作用于它** ⇒ 失败原因**未解释**（本文的诚实缺口）；- **v4/v5**：选择器存在，但**代价几乎不存在** ⇒ 失败原因**较明确**（代价没被生成）。

⇒ ⇒ 我们由此得到下一步的设计要求：**必须同时具备"代价真实存在"与"选择器读得到它"**，并让代价**真的改变排序**；否则测的仍不是驱动力。⇒ ★ **诚实标注**：本节的 v3 数字是**事后重算**（无事前预注册）⇒ 按本文的证据标签纪律，属 ◐ **探索性**，但它只用于**收窄一条已被否证的普遍性主张**共享根因「(」），不用于支持任何新的正面结论。

8 结论

我们从「让 Agent 的输出由**目的**（思想/情感）推动，而不是仅由下一个词的概率决定」这一问题出发，做了五件事（v1–v5 架构化状态机）。

第一，把"驱动"拆成三条通路，并给出各自的读数与地板。反馈通路（观测 → 状态 → 产出）成立且强分离（9.13×）；驱动力通路（取舍内容 → 产出）需要一条**不循环**的读数才能测；**选择层通路**（状态 → 候选集合 → 选择，v4/v5 新增）要求同池比较两个打分器，并以"候选拿不到状态内容"作为地板。

第二，指出了一个被忽视的方法论陷阱并给出修正。当状态经由**代码强制**生效时，「状态变了 ⇒ 产出变了」是 **恒真命题**，不能充当驱动力证据；我们把它写成一条可迁移的检查题：「**这个读数能不能是恒真的?**」这条检查题在 v4 上**于实验开始 5 分钟后命中**（候选提示告知了打分依据 ⇒ 打分接近恒真 ⇒ 7 条数据作废重跑），在 v5 上则被写成了三**条机制性保障**（提示不含状态决定 / 候选不知答案 / 绑定用编号离散量）加一条自检（随机声明的对齐分 0.335 必须远低于正确声明的 1.0）。我们进一步量化了判官读数的三种失效模式（天花板效应、位置偏差、严格度差异），并把**位置去偏 + 一致率硬闸**作为 LLM-as-judge 成对比较的标准前置条件。

第三，发现我们自己的负结果是读数错配的产物。在几何读数（实词 2/3-gram Jaccard）上，全部臂对落在 0.053–0.077 的窄带内，纯重跑地板（0.0720）高于信号；而在**对着目标直接问的判官两**

两比较上，同一批产出给出**方向相反**的分离。⇒ **在创作任务上，「状态是否驱动了产出」不能用产出之间的相似度来回答**。

第四，把"驱动力"从一种内容改写为一个结构，从而使情感与观点统一。我们主张 **驱动力 = 状态 → 改变了哪一个可核验的选择 → 代价是什么**（§7.8）。情感与观点是同一类对象（都是约束下一步动作的持久状态），因而可用**同一套取舍层读数**测量；这同时把"文中有无感情词 / 有无观点句" 这类**素材层**判据排除在外，并给出一个可证伪的**类型不变性**主张。⚠ 诚实边界：v1–v5 测的**全部是观点型状态**，情感型状态一次都没进过实验 ⇒ 我们的结论**不可外推到情感**。

第五 ★，把三代架构的失败收敛到一个统一诊断上。 v3（状态进提示层）与 v4（状态进选择层）都失败，v5（编号化声明 + 结构化绑定）给出了一个**方向一致但未达阈值**的微弱差距（3 胜 0 负 15 平，gap +0.088）。我们最终定位到的根因**不在选择器，而在状态本身**：

> **18 个工作流样本、54 个决策里，只有 3 个（6%）是"放弃"**。第四组的靶子是「**有立场的 Agent 必须放弃一个更优候选**」，而我们的状态构建**几乎不产生"放弃"** ⇒ **取舍代价这一层根本没有被生成出来** ⇒ 状态里没有代价，也就无所谓驱动力。
>
> ⚠ ⚠ **【限定，2026-10-24 补】这条统一诊断只覆盖 v4/v5，不覆盖 v3**。v3 的决策分布事后重算为 **"放弃"占 15%（4/26）、4/9 = 44% 的样本含"放弃"——v3 有代价，仍然失败** ⇒ ⇒ **"有代价"不是充分条件** ⇒ ⇒ 代价必须**进入选择器的排序**才可能起作用 ⇒ ⇒ **v3 的失败因此保持未解释**，这是本文留下的一个诚实缺口（§7.9）。

⇒ 与此同时，v5 量化了一个**独立于"放弃"是否常在**的量：**候选自己声明"我要写透 X"时，只有 52.8% 真的在正文里写到了；声明"放弃 Y"时，仍有 33.3% 写了 Y**。 ⇒ ⇒ **"说了取舍"不等于"做了取舍"**：产出的可核验证据不是"它声明了什么"，而是"**它实际上放弃了什么**"。⇒ 任何以**自述**为判据的读数都不可信（这同时是我们对判官读数与自评偏差的一般性警告）。

⇒ **本文不主张**状态机已经能"驱动"Agent。本文主张的是五件更小但更牢的事：(i) 三条通路各自的读数与地板；(ii) 一条不循环读数的必要性与可迁移的检查题；(iii) 三种判官失效模式的量化与硬闸；(iv) 一次读数错配如何制造出一个看起来干净的负结果；(v) ★ **一次跨代际的失败收敛：从"改进选择器"改写为"让取舍代价真实存在"**，并给出一个可操作的下一步——**把"放弃"变成状态构建的结构性配额**（而非提示偏好），且把判据从**声明**移到**行为**（兑现率 / 违禁率）。

⇒ 若"驱动"最终必须进入训练与采样（[Nagarajan et al., ICML 2025 oral] 从训练侧给出的结论），那么本文的贡献就明确地是一**个定位**：它把这份责任从推理时架构指回去，同时给出一套可以廉价复用的检验工具；并给出一条**廉价的前置检查**—— 在投入训练侧改造之前，先测出推理时架构的上限：**若连"有状态 vs 等预算自我说明"都测不出分离，训练侧改造就是必需的而非可选的**。

参考文献

> 全部条目**逐条核实原始出处**（arXiv API / 期刊页 / 官方仓库）。核验底稿见 `LIT_2026-10-23_ 驱动定位.md` 与 `../第四组论证.md` §6。⚠ 标注"降级"的条目表示原始出处不支持更强的说法。

[1] Nagarajan, V., Wu, C. H., Ding, C., & Raghunathan, A. (2025). Roll the dice & look before you leap: Going beyond the creative limits of next-token prediction. arXiv:2504.15266. **ICML 2025 (oral)**. → NTP 学不到「先想一个抽象点子再围绕它生成」；解法是换训练目标（teacherless / diffusion）+ seed-conditioning 把随机性从输出端挪到输入端。在**算法任务**上做（真实写作"没法量化"）。☒ CONFIRMED

[2] Olatunji, I., & Sheppard, M. (2025). Next Token Prediction Is a Dead End for Creativity. arXiv:2505.19277. 10 pages. → 架构倾向表面连贯而非自发性/原创性/即兴风险；把创造力重新定义为互动过程。**perspective 论文，非实验** ⇒ 不得当作"已有实验支持"引用。☒ CONFIRMED

[3] Sui, P. (2026). LLMs Exhibit Significantly Lower Uncertainty in Creative Writing Than Professional Writers. arXiv:2602.16162. McGill University, Department of English. → 人

类—模型不确定性差距：NLL 比率中位 2.03–3.9；ΔPMI 全负（−1.44～−2.60）；指令微调与 thinking 模型**扩大**差距；质量与不确定性呈倒 U（$z^* \approx 1.98\sigma$）。**PMI/CPMI 抵消自评偏差**。局限：只捕捉创造力的统计侧面。☒ CONFIRMED

[4] Bender, E. M., Gebru, T., McMillan-Major, A., & Mitchell, S. (2021). On the dangers of stochastic parrots: Can language models be too big? FAccT ’21, 610–623. doi:10.1145/3442188.3445922. → "probabilistic information"的经典表述；本文的"概率检索"一语的来源。☒ CONFIRMED

[5] Shu, M., Karell, D., Okura, K., & Davidson, T. R. (2026). How latent and prompting biases in AI-generated historical narratives influence opinions. PNAS Nexus, 5(3), pgag022. doi:10.1093/pnasnexus/pgag022. → 1,912 人预注册实验：叙事框架偏移读者立场。⚠ **效应量小**（5 分制 3.47→3.57/3.67/3.36）⇒ 只能支撑"外部指令能改变内容层"，**不能**支撑"模型自担状态能改变内容层"。☒ CONFIRMED

[6] The Analyst in the Prompt (2026). arXiv:2609.03218. → 3,575 SEC filings × 12 个 LLM；「most user-context spillover comes from how models **interpret the same evidence under different roles**, rather than from retrieving different evidence」；persona 面板保留 69% 的 PR 效应（模型级 44–89%）⇒ **persona 走解释通道而非检索通道**。☒ CONFIRMED

[7] When Does Persona Prompting Actually Help? (2026). arXiv:2605.29420. → 1,140 题 × 38 专家角色；「Aggregate results show only small overall differences」；「role prompting systematically increases expertise depth while reducing clarity」。⚠ 4.35/4.39 两数待回原表。☒ 部分 CONFIRMED

[8] Barriers to Diversity in LLM-Generated Ideas (2026). arXiv:2602.20408. → 普通 persona 提升 knowledge partitioning；「creative entrepreneurs such as Steve Jobs」反而降低。☒ CONFIRMED

[9] Harel-Canada, A., et al. (2024). Measuring Psychological Depth in Language Models. EMNLP 2024. arXiv:2406.12680 = aclanthology 2024.emnlp-main.953. → 心理深度可测（α=0.72、ρ=0.51、empathy 0.68）。⚠ **"Outstanding Paper"的说法找不到证据 ⇒ 降级为"EMNLP 2024 论文"**。☒ 已消歧

[10] Porter, B., & Machery, E. (2024). AI-generated poetry is indistinguishable from human-written poetry and is rated more favorably. Scientific Reports, 14, 26133. doi:10.1038/s41598-024-76900-1. → ⚠ **此处曾长期被误署为 "Stiff & Johansson 2024"**；三路反查（Crossref / Europe PMC / arXiv）均无该署名 ⇒ 已消歧。☒ CONFIRMED

[11] ESFP (2026). arXiv:2607.12739. → "Vocabulary is not stance."；δAR−δSCD 在 P0 解离；「Any benchmark of subjective expression that reads only the surface will be gamed by exactly that move.」；AR 权重最小 inserting ’I think’ costs nothing「(」；**构念效度未经人类验证**。☒ CONFIRMED

[12] Tian, et al. (2024). arXiv:2407.13248. → IAA 0.90 (Spearman) + 0.62 (Cohen’s κ)；「more than half of the time」（Man in Hole）。⚠ 30.7% 不可核 ⇒ 部分 CONFIRMED

[13] ConflictingQA (2024). arXiv:2402.11782. → "stylistic features play a considerably less impactful role in determining the convincingness of text than measures of relevance"; perplexity/sentiment 影响很小。☒ CONFIRMED

[14] Bhalla & Gligorić (2026). SWAY. arXiv:2604.02423. → 谄媚度量：预设立场极性配对提示 + 反事实 CoT。☒ CONFIRMED

[15] Chakrabarty, T., Laban, P., Agarwal, D., Muresan, S., & Wu, C.-S. (2024). Art or artifice? Large language models and the false promise of creativity. CHI ’24, 1–34. → LLM 创造力评测的现况综述。☒ CONFIRMED

附录 A ·复现清单

A.1 代码

文件	作用
workflow_arch3.py	架构化状态机 v3：封闭枚举决策、代码推导必含/禁含、NL 通道渲染（自检 18/18）
run_arch3_compare.py	v3 主实验（6 臂），支持 --batch-id / --append 做**同批补跑**
probe_arch3.py	探针：D0 纯重跑 / D2’ 换决策 / D3 无关议题
analyze_arch3.py	v3 分析（封闭率、语言闸门、取舍执行、探针汇总）
run_multitopic.py	多题扩展（**极简题面**：只给情境 + 任务，不带题库装饰）
analyze_multitopic.py	多题零判官分析（**修正后的语言闸门**）
judge_selfcheck.py	判官自检（双判官、盲化、长度分层、Spearman）
judge_driver.py	判官绝对打分（三维度 × 双判官）
judge_pairwise.py	★ 两两比较（**位置去偏** + **一致率硬闸**），支持 openrouter / minimax 两个后端
build_paper_tables.py	★ 程序化生成论文表格（杜绝手抄错误）
api_any.py	传输层：MiniMax / OpenRouter 双端点，thinking 策略、超时、失败显式标记
PREREG_v3.md	预注册（含 **4 条判据修正留痕**，均写明"探针结果产生前"）
workflow_arch4.py	★ v4：状态进选择层。**否定语境识别**提到但放弃「」不算命中）、**blind 提示**、tiebreak（自检 25/25，含变异注入）
run_arch4_compare.py	v4 主实验（3 臂：A / WF-v4 / WF-v4-blind）
analyze_arch4.py	v4 分析（**分臂 H3**、Fisher、措辞判据）
build_arch4_tables.py	★ v4 读数表**程序化生成**
PREREG_v4.md	v4 预注册（补充 2/3 结果前、补充 4 **结果后并标注**）
workflow_arch5.py	★★ v5：**编号化取舍声明** + **结构化绑定**。parse_declaration / score_state_alignment5 / score_fulfillment5 / score_violation5 / score_generic5（自检 33/33）
run_arch5_compare.py	v5 主实验（3 臂：A / WF-v5 / WF-v5-blind）
analyze_arch5.py	v5 分析（分臂 H3′、地板、状态信息增量）
PREREG_v5.md	v5 预注册（含 3 条留痕，注明写入时点）

A.2 数据

文件	内容
runs/arch3_compare.jsonl	v3 主实验（G01，6 臂，含同批补跑）
runs/arch3_probe.jsonl	v3 探针（D0 / D2’ / D3）
runs/arch3_analysis.json	v3 分析结果
runs/multitopic_T{06,07,10}/mt_*.jsonl	多题扩展（3 道干净题）
runs/judge_selfcheck.json	判官自检
runs/judge_driver_v3.json	绝对打分（双判官 × 三维度）
runs/judge_pairwise_multi.json	两两比较（MiniMax 判官，全部 4 题）
runs/_smoke_pw.json	两两比较（grok 双判官，G01）
runs/multitopic_analysis.json	多题零判官读数

文件	内容
runs/paper_tables.md	程序化生成的论文表格
runs/arch4_compare.jsonl	★ v4 主实验（3 题 × 3 臂 × 3 重复 = 27 条，0 失败，144 次调用）
runs/arch4_analysis.json	v4 分析结果
runs/arch4_tables.md	v4 读数表（程序化生成）
runs/arch5_compare.jsonl	★★ v5 主实验
runs/arch5_analysis.json	v5 分析结果

A.3 关键命令

```
# 判官自检（先证明检查器能抓到东西）
python3 judge_selfcheck.py --out runs/judge_selfcheck.json

# 判官两两比较（位置去偏 + 一致率硬闸）
python3 judge_pairwise.py --src runs/arch3_compare.jsonl \
    --out runs/pw_grok.json --judges x-ai/grok-4.20 x-ai/grok-4.3
python3 judge_pairwise.py --src runs/multitopic_T*/mt_*.jsonl \
    --out runs/judge_pairwise_multi.json --judges MiniMax-M3

# 多题扩展（极简题面）
python3 run_multitopic.py --topics T06,T07,T10 \
    --arms A,S-self,WF-a3-NL,WF-a3 --reps 1,2,3 --workers 2

# 零判官分析 + 论文表格（程序化生成）
python3 analyze_multitopic.py && python3 build_paper_tables.py
```

A.4 复现注意事项（踩过的坑）

★ v4 / v5 新增（全部为「看起来没问题、实际上结论会错」的坑）：

1. **嵌套线程池 ⇒ 9 并发 ⇒ MiniMax 429 雪崩**：v5 首轮把外层样本并发（3）与内层候选并发（3）叠在一起 ⇒ 总并发 9 ⇒ 触发 Token Plan 429 ⇒ 退避 20/40/60 s ⇒ 实验慢到不可用（20 分钟只跑出 5 条）。⇒ **修法**：内层候选生成改**串行**，总并发 = 外层 workers（≤4）。⇒ **教训：并发上限要按"全局"算，不能按"每层"算**。
2. **候选提示若告知打分依据 ⇒ 打分接近恒真**：v4 第一版提示给出了"缺口涉及的具体词" ⇒ 候选照做就能命中 ⇒ H3 失去意义。⇒ **启动 5 分钟后主动终止**（不是跑完再看），7 条已落盘数据作废重跑。⇒ 这就是 §4.4 那条检查题在**跑前**命中。
3. **逐字包含把"提到但放弃"算成命中**：「这篇写甲不写丙」里"丙"逐字出现 ⇒ 被算成"写了丙" ⇒ 取舍语义根本测不出来。⇒ **修法**：否定语境识别（实体前 14 字窗口含否定标记 ⇒ 计为回避）。
4. **候选声明完全相同 ⇒ 选择器无从区分**：v5 首轮三个候选的取舍声明一模一样 ⇒ 状态化打分给它们同样的分 ⇒ H3′ 不可测。⇒ **修法**：提示只给"你是第几次尝试"，让候选自己差异化（**不给任何取舍信息** ⇒ 不引入状态泄漏）。
5. **打分项在"状态无该项决策"时不得当 0 惩罚**：状态三个缺口全判"深入展开"（放弃集为空）⇒ 放弃维度被当 0 ⇒ 所有候选一起被拉低、真实差异被掩盖。⇒ **修法**：该项只在状态对该项**真有决策**时计入。
6. **分析脚本的臂过滤写成硬编码 ⇒ 一个臂整个漏掉**：`arm == 「WF-v4」` 漏掉了 `WF-v4-blind`（9 条）⇒ 判决会落在错的臂上。⇒ **修法**：**凡要按臂分组读的数，先打 n 验范围**（分臂 H3 打出 n=0 才发现）。
7. **措辞判据的第一版有假阳性**：把"以避免加重课业负担"当成取舍声明 ⇒ **修法**：收紧后逐句人工核验（3/3 真、假阳性 0）。

坑	处置
重试型硬闸若写成 `any(not ok)` ⇒ 重试后**最终通过**的样本被误标失败	改为看**最后一次**尝试
位置参数 > 3 个 ⇒ decisions/obs 传反，报 `'list'/'str' object has no attribute 'get'`	全用关键字或逐位注释
跨模块改函数返回个数 ⇒ `ValueError: not enough values to unpack`	改签名必须全仓搜调用点
prompt 里含 JSON 示例的花括号 ⇒ `.format()` 吃掉占位符	改用 `str.replace`
判官 `max_tokens=200` ⇒ evidence 较长时被截断 ⇒ JSON 不可解析	提到 600，并**保留原始返回**便于诊断
OpenRouter **403 `Key limit exceeded (total limit)`** ≠ 限流，是 key 总额度耗尽且不自动重置	403/429/404 必须**分类**并抛错，不得静默当"解析失败"
语言闸门用"整体中文占比 ⩾0.9" ⇒ **误杀**含 markdown 标记与英文术语的中文长文	改判"**是否存在整段非目标语言**"
多题 runner 漏记 `lang_cn_ratio` ⇒ 语言闸门根本没跑	分析时自己算，不依赖记录字段

附录 B ·判官失效模式速查

失效	现象（本文实测）	检测方法	处置
天花板效应	判官 4.20 在 D1 上把 18 篇全打 3.000	分数分布集中	改两两比较；或换更严判官
位置偏差	多对对比胜负"3 胜 3 负"，位置一致率 **0.00**	**交换位置各跑一次**，算一致率	一致率 < 0.5 的对比**直接判不可用**
严格度差异	4.20 方差 0.49、4.3 方差 1.86	同一批样本的分数分布	只用**题内相对排序**
饱和的"无差异"	D3 上两判官全打 4.000	分布无差异	该维度弃用，**不得**写成"两臂无差异"
同源偏好	判官与被测同厂商 ⇒ 共享偏好	换跨厂商判官对照	同源判官只作**交叉验证**，不作主判据
额度耗尽伪装成解析失败	78/144 任务"解析失败"，实为 403	看**错误类型**而非只计数	分类 403/429/404 并重试或换源

⇒ **本文主张**：以上六项应成为"用 LLM 判官测状态是否驱动产出"这类研究的**标准前置检查**。其中「位置偏差」一项尤其关键：不做位置去偏，一个**随机作答**的判官会产出"3 胜 3 负"这类看起来像"无差异"的结论。